

L3 INFORMATIQUE

Institut Galilée — Université Sorbonne Paris Nord

**Analyse expérimentale des biais
dans les grands modèles de langage
par exploration guidée de graphes de
connaissances**

Rapport d'étude de fin de licence

réalisé par

ADIBA DETCHE
JEGATHEESWARAN HAARISH
IRNATENE GAYA
MADIVANANE KEVIN

sous la direction de

Amal Beldi

Juin 2026

Table des matières

1	Introduction	2
1.1	Contexte général	2
1.2	Problématique	2
1.3	Objectifs du projet	2
1.4	Organisation du rapport	3
2	État de l’art	4
2.1	Biais dans les grands modèles de langage	4
2.2	Méthodes classiques d’évaluation des biais	5
2.3	Limites des benchmarks fixes	6
2.4	Graphe de connaissances	7
3	Méthodologie générale	8
3.1	Présentation de l’approche Proposée	8
3.2	Construction du graphe de connaissances	8
3.3	Génération automatique des prompts	9
3.4	Interrogation des modèles de langage	9
4	Analyse et Détection des biais	10
4.1	Méthode d’analyse des réponses	10
4.2	Evaluation des biais à travers les scores	10
4.3	Sélection intelligente des prompts	10
5	Résultats expérimentaux et discussion	10
5.1	Présentation des résultats	10
5.2	comparaison des stratégies et des modèles	10
5.3	Limites de l’approche	10
6	Contribution et Difficultés	10
6.1	Kevin MADIVANANE :	10
6.2	Detche ADIBA :	10
6.3	Haarish JEGATHEESWARAN :	10
6.4	Gaya IRNATENE :	10
7	Conclusion et perspectives	10

1 Introduction

1.1 Contexte général

Depuis la popularisation des grands modèles de langage ou *Large Language Models* (LLM) avec l'arrivée de ChatGPT en 2022, ceux-ci sont utilisés fréquemment dans nos activités quotidiennes, qu'il s'agisse de répondre à une question, de faire la synthèse d'un document, d'assister la programmation ou encore d'aider à la prise de décision. Leur entraînement sur de grandes quantités de données issues de sources variées les rend vulnérables à la propagation ou à l'amplification de biais possibles.

En effet, les LLM sont entraînés sur des données textuelles massives issues de sources variées. Ces données contiennent souvent des stéréotypes relatifs au genre, à l'origine géographique, à la culture, aux professions ou encore au niveau socio-économique. Par conséquent, ces biais se propagent dans les réponses aux interrogations, parfois sous une forme directe ou même implicite. Il est donc d'un certain intérêt d'étudier ces biais afin de mieux comprendre les limites de ces systèmes et d'évaluer leur comportement dans différents contextes.

1.2 Problématique

L'évaluation des biais dans les LLM est une tâche complexe, notamment en raison du très grand nombre de situations possibles à évaluer. Il est en effet impossible d'interroger un modèle sur toutes les combinaisons d'entités, de relations et de contextes possibles. Cette complexité est d'autant plus renforcée par le caractère implicite de certains d'entre eux, qui ne sont pas évoqués directement mais par le choix des mots et leur arrangement dans les réponses.

D'où l'importance de poser la problématique suivante dans ce projet : Comment évaluer efficacement les biais d'un grand modèle de langage sans examiner chaque fait d'un graphe de connaissances ? Cette problématique nécessite donc de construire une approche permettant de stocker les connaissances de façon structurée pour ensuite y générer des requêtes et analyser les réponses pour trouver des biais potentiellement présents.

1.3 Objectifs du projet

Pour répondre à notre problématique, nous avons l'ambition de définir une démarche expérimentale permettant d'évaluer les biais d'un grand modèle de langage à partir d'un graphe de connaissances. Ce dernier permettra d'enregistrer des entités de différents types (genres, professions, compétences, secteurs, lieux géographiques, etc.) ainsi que des relations. À partir de ce graphe, nous pouvons générer des prompts permettant de tester les différents modèles de langage.

Les objectifs spécifiques de ce projet sont donc les suivants :

- Construire un graphe de connaissances adapté.

- À partir de ce graphe, générer différents prompts (directs, neutres, contextuels).
- Tester ceux-ci sur plusieurs modèles de langage (LLM).
- Analyser les réponses à travers des catégories et des scores, et déterminer quels prompts permettent de repérer les réponses les plus biaisées.
- Réfléchir à une stratégie de sélection intelligente des prompts pour maximiser la quantité de biais détectés tout en minimisant la taille de l'échantillon de prompts.

1.4 Organisation du rapport

Ce rapport se structure en plusieurs parties. Dans un premier temps, on rappellera les aspects scientifiques liés à cette problématique, c'est-à-dire la notion de biais dans les grands modèles de langage et les méthodes classiques d'évaluation et leurs limitations, en particulier les benchmarks fixes.

Ensuite, nous exposerons la méthodologie globale de ce projet, de la conception du graphe de connaissances à l'analyse des biais à partir des réponses des modèles de langage.

La troisième partie détaillera plus précisément la construction du graphe, la génération automatique de prompts puis le processus d'interrogation des modèles de langage. On s'attardera aussi sur l'analyse et la détection de biais à partir des réponses obtenues. Puis sera exposée la stratégie de sélection intelligente des prompts.

Le rapport conclura par une analyse des résultats expérimentaux puis des limites du projet ainsi que quelques perspectives d'avenir.

2 État de l’art

2.1 Biais dans les grands modèles de langage

Les LLM sont entraînés sur de très grands volumes de textes, ce qui leur permet de répondre de manière pertinente à des instructions variées et de couvrir plusieurs besoins du quotidien humain. Toutefois, ce mécanisme d’apprentissage peut également conduire à la reproduction, par ces modèles, de biais présents dans les données d’entraînement. Comme le soulignent certains travaux, « on considère qu’un biais dans un modèle de langue correspond à une forme de déviation systématique par rapport à ce qui est attendu, que cette attente soit fondée sur une norme statistique, une norme sociale ou une norme éthique » [4].

Un biais dans un grand modèle de langage désigne toute tendance systématique et reproductible du modèle à produire des sorties qui favorisent, défavorisent ou distordent la représentation de certains groupes, concepts ou points de vue, de manière non justifiée par les données. Ces biais émergent principalement des corpus d’entraînement, qui reflètent les inégalités et les stéréotypes présents dans les productions humaines. Il en existe plusieurs types : les biais sociaux (inégalités entre groupes sociaux), culturels (valorisant certaines cultures au détriment d’autres), géographiques (liés aux conditions de vie des populations selon le niveau de développement de leur pays), de genre (stéréotypes et asymétries liés au genre) et économiques (reproduction des inégalités de classe et de richesse). Ces différentes formes de biais, bien qu’analytiquement distinctes, sont souvent interdépendantes et se renforcent mutuellement dans les sorties des modèles.

Ces biais ne se limitent cependant pas à la seule composition intrinsèque des contenus utilisés pour l’entraînement. En effet, ils peuvent prendre plusieurs formes, au-delà du simple déséquilibre statistique des données. Comme le précisent les auteurs, « les biais dans les modèles de langue ne sont pas uniquement des biais statistiques (représentation déséquilibrée dans les données), mais peuvent aussi être des biais sémantiques (représentations stéréotypées de concepts), des biais sociétaux (préjugés sociaux reproduits) ou des biais cognitifs (modèles reflétant des heuristiques humaines) » [4].

En ce sens, le biais peut se présenter de manière explicite : le modèle généralise un groupe social, ou de manière implicite au travers de la formulation de la réponse, du vocabulaire ou du ton utilisé, des exemples proposés. La manière d’évaluer le biais devient donc une variable cruciale compte tenu de toute la diversité présente.

2.2 Méthodes classiques d'évaluation des biais

Les méthodes classiques d'évaluation des biais dans les grands modèles de langage reposent généralement sur l'utilisation de benchmarks, c'est-à-dire des ensembles standardisés de phrases, de questions ou de contextes soigneusement construits pour mesurer si un modèle tend à favoriser certaines associations stéréotypées. Ces jeux de données de référence permettent de sonder le comportement du modèle face à des situations contrôlées, en comparant par exemple ses réponses selon le genre, l'origine ethnique ou la catégorie sociale des sujets évoqués. Il existe plusieurs approches de benchmarks, chacune ciblant des formes spécifiques de biais. Toutefois, ces approches présentent certaines limites : elles ne capturent qu'une portion restreinte des biais possibles, et leurs résultats peuvent être sensibles à la formulation des exemples ou au contexte culturel dans lequel ils ont été conçus.

Différentes approches sont utilisées :

- **Paires minimales (CrowS-Pairs)**. On compare deux phrases presque identiques, dans lesquelles seule une variable sensible change (par exemple, « homme » vs « femme »). Si le modèle produit systématiquement une réponse plus favorable pour l'un des deux groupes, ou s'il associe plus fortement un groupe à une profession ou une compétence, cela peut indiquer un biais. CrowS-Pairs repose sur cette logique de paires contrastives, avec des phrases stéréotypées et moins stéréotypées [5].
- **Choix multiples et continuations (StereoSet)**. On propose au modèle une phrase incomplète ou plusieurs choix de réponse. StereoSet mesure les associations stéréotypées dans plusieurs domaines : genre, profession, race et religion [3]. L'objectif est d'observer si le modèle préfère une continuation stéréotypée à une continuation anti-stéréotypée ou neutre.
- **Question-réponse avec contexte (BBQ)**. BBQ propose des contextes ambigus ou informatifs pour étudier si un modèle s'appuie sur des stéréotypes lorsqu'il ne dispose pas de suffisamment d'information pour répondre correctement [6]. Cette distinction est importante car un modèle peut produire une réponse biaisée précisément lorsqu'il doit compléter une information manquante à partir de ses associations internes.
- **Génération ouverte de texte (BOLD)**. BOLD propose des prompts permettant d'étudier les biais dans des générations libres, avec des mesures comme la toxicité, la polarité de genre ou certaines propriétés psycholinguistiques [1]. L'analyse porte alors sur le contenu textuel produit, et non sur un simple choix entre plusieurs réponses.

Ces méthodes classiques peuvent être complétées par différentes mesures automatiques :

- **Analyse lexicale.** Elle consiste à rechercher dans les sorties du modèle des mots ou expressions associés à des stéréotypes, en s'appuyant sur des lexiques spécialisés. On compare les réponses générées pour différents groupes afin de repérer des termes discriminatoires récurrents.
- **Analyse de sentiment.** Elle mesure les variations de polarité affective dans les réponses selon le groupe mentionné. On génère des réponses pour des contextes identiques en faisant varier uniquement le groupe de référence, une asymétrie systématique constituant alors un indicateur de biais.
- **Mesures de similarité sémantique.** Elles quantifient le degré d'association que le modèle établit entre certains groupes et certains concepts via la proximité vectorielle dans l'espace d'embeddings. Cette méthode révèle des biais subtils invisibles à une simple analyse lexicale.
- **Règles et outils de détection.** Des outils automatisés évaluent le niveau de toxicité ou de contenu discriminatoire dans les réponses générées, en filtrant les sorties problématiques selon des seuils prédéfinis. Bien qu'efficaces à grande échelle, ces outils peuvent souffrir de leurs propres biais.

2.3 Limites des benchmarks fixes

Un benchmark est un ensemble standardisé de données de test, composé de phrases, de questions ou de contextes soigneusement construits, permettant d'évaluer et de comparer les performances d'un modèle sur une base commune et reproductible. Dans le contexte de l'évaluation des biais, ils servent à mesurer si un modèle favorise certaines associations stéréotypées de manière systématique, en soumettant le modèle à des situations contrôlées impliquant des groupes sociaux, culturels ou de genre.

Ces outils sont particulièrement utilisés lors de la phase de validation des modèles, que ce soit pour comparer différentes versions d'un même modèle ou établir des comparaisons entre modèles concurrents. Ils constituent ainsi une référence commune pour mesurer les progrès réalisés dans la réduction des biais.

Cependant, leur caractère fermé limite l'exploration aux biais déjà prévus par les concepteurs. Ils détectent plus difficilement certains biais implicites et se heurtent à un mur lorsqu'une même requête est soumise à une expansion contextuelle ou relationnelle. Par exemple, une question simple sur les femmes et l'ingénierie peut produire une réponse neutre, tandis qu'une requête plus contextualisée, associant genre, profession et origine, peut révéler des différences de traitement significatives. Dans cette perspective, les graphes de connaissances offrent une piste intéressante : ils permettent de représenter explicitement un domaine sous forme d'entités, de relations et d'attributs, puis de générer automatiquement des requêtes à partir de triplets. Cette approche ne remplace pas les benchmarks classiques, mais les complète en rendant les requêtes plus variées et mieux adaptées à l'exploration de biais contextuels ou relationnels.

2.4 Graphe de connaissances

Selon Hogan et al., un graphe de connaissances peut être défini comme un graphe de données destiné à accumuler et transmettre des connaissances sur le monde réel. Ses nœuds représentent des entités d'intérêt, tandis que ses arêtes représentent des relations entre ces entités [2]. Cette définition reste générale : un graphe de connaissances peut ensuite être représenté selon différents modèles de graphes, par exemple un modèle RDF fondé sur des triplets sujet-prédicat-objet, ou un graphe de propriétés comme ceux utilisés dans Neo4j.




FIGURE 1 – Illustration d'un graphe de connaissances centré sur des œuvres illustrant Socrate. Source : Wikimedia Commons.

3 Méthodologie générale

3.1 Présentation de l’approche Proposée

La démarche adoptée dans ce projet s’articule en trois grandes étapes, allant de la collecte des données à la visualisation des biais détectés, en passant par l’interrogation de plusieurs grands modèles de langage.

La première étape consiste à rassembler des données relatives à différentes catégories d’entités : les pays, les métiers, les qualités personnelles, le genre ainsi que le niveau socio-économique. Ces données constituent la matière première à partir de laquelle est construit un graphe de connaissances. Ce graphe permet de représenter explicitement les relations entre les différentes entités, par exemple les associations entre métiers et qualités attendues, les représentations de genre liées à certaines professions, ou encore les liens entre les individus et leur origine géographique ou leur niveau socio-économique. Cette représentation structurée constitue la base sur laquelle repose toute la suite de l’analyse.

À partir des relations identifiées dans le graphe de connaissances, des prompts sont générés automatiquement. Ces prompts sont ensuite soumis à trois grands modèles de langage : le premier est utilisé pour la génération initiale des prompts, tandis que les deux autres fournissent des réponses comparatives. Cette approche multi-modèles permet de collecter un maximum de réponses variées et d’identifier les divergences potentielles entre les modèles. Les réponses obtenues sont ensuite analysées afin de détecter les biais présents, qu’ils soient d’ordre lexical, sémantique ou de sentiment, et de déterminer quels prompts sont les plus révélateurs de comportements biaisés.

Enfin, les résultats sont présentés sous forme d’un tableau de bord synthétique, permettant de visualiser les biais détectés par modèle et par catégorie d’entité. En parallèle, une stratégie de sélection intelligente des prompts est proposée, avec pour objectif de réduire la taille de l’échantillon tout en maximisant la quantité de biais détectés, en ciblant en priorité les combinaisons d’entités les plus susceptibles de générer des réponses biaisées.

3.2 Construction du graphe de connaissances

3.3 Génération automatique des prompts

FIGURE 2 – script générateur de prompt.

La génération des prompts repose sur un mécanisme de complétion automatique de gabarits de phrases partiellement rédigées. Concrètement, des modèles de phrases sont définis à l’avance avec des emplacements variables, que le script remplace systématiquement par les données issues du graphe de connaissances. Par exemple :

« En [pays], quelles sont les personnes les plus susceptibles d’exercer le métier de [métier] ? »

cette phrase va produit automatiquement un prompt distinct pour chaque combinaison de pays et de métier présente dans le graphe, multipliant ainsi le nombre de prompts générés. Cette approche est appliquée à l’ensemble des types de prompts définis directs, neutres et contextuels en faisant varier les entités impliquées (pays, métier, genre, qualité, niveau socio-économique). selon les relations modélisées dans le graphe.

L’ensemble des prompts ainsi générés est ensuite transmis à un premier modèle de langage, dont le rôle est d’envoyer ces prompts aux deux autres modèles. Ce choix permet d’envoyer chaque prompt à deux modèles différents et d’obtenir des réponses indépendantes . Ces réponses obtenues offre ainsi une base d’analyse comparative solide : il devient possible de confronter les réponses des modèles selon le type de prompt (direct, neutre ou contextuel), d’identifier les formulations les plus révélatrices de biais, et de mesurer dans quelle mesure les modèles divergent dans leurs représentations des entités étudiées.

ici il faudrait spécifier les outils utilisé et une image du code qui cree les prompts et comment tu relie les donne des pays, metiers qualité, genre sur le scripts

3.4 Interrogation des modèles de langage

Une fois les prompts générés, un second script collecte les réponses. Pour chaque prompt envoyé, le script récupère la réponse de chaque modèle. Il enregistre ensuite ces réponses dans un fichier CSV. Chaque ligne du fichier contient l’identifiant du modèle ayant répondu. Elle contient aussi le prompt soumis, la réponse obtenue et la température utilisée.

Ce format présente plusieurs avantages pour le projet. Il organise toutes les réponses de façon claire et consultable. Il permet de savoir quel modèle a répondu à quel prompt. Il conserve aussi les paramètres utilisés lors de chaque interrogation. Ces fichiers CSV sont ensuite utilisés directement pour l’analyse des biais. Ils servent de base d’entrée aux outils de traitement statistique.

ici il faudrait specifier les outils utilisé et une image du code qui cree les prompts et comment tu relie les donne des pays, metiers qualité, genre sur le scripts. cette parti n'est pas encore clair de comment vous metez les données dans les fichier reponses csv

4 Analyse et Détection des biais

4.1 Méthode d'analyse des réponses

4.2 Evaluation des biais à travers les scores

4.3 Sélection intelligente des prompts

5 Résultats expérimentaux et discussion

5.1 Présentation des résultats

5.2 comparaison des stratégies et des modèles

5.3 Limites de l'approche

6 Contribution et Difficultés

6.1 Kevin MADIVANANE :

6.2 Detche ADIBA :

6.3 Haarish JEGATHEESWARAN :

6.4 Gaya IRNATENE :

7 Conclusion et perspectives

faudrait penser a mettre des images

Références

- [1] Jwala Dhamala, Tony Sun, Varun Kumar, Satyapriya Krishna, Yada Pruk-sachatkun, Kai-Wei Chang, and Rahul Gupta. BOLD : Dataset and metrics for measuring biases in open-ended language generation. In *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency*, FAccT '21, pages 862–872, New York, NY, USA, 2021. Association for Computing Machinery. doi : 10.1145/3442188.3445924. URL <https://doi.org/10.1145/3442188.3445924>. Dataset et code : <https://github.com/amazon-science/bold>.

- [2] Aidan Hogan, Eva Blomqvist, Michael Cochez, Claudia d’Amato, Gerard de Melo, Claudio Gutierrez, José Emilio Labra Gayo, Sabrina Kirrane, Sebastian Neumaier, Axel Polleres, Roberto Navigli, Axel-Cyrille Ngonga Ngomo, Sabbir M. Rashid, Anisa Rula, Lukas Schmelzeisen, Juan Sequeda, Steffen Staab, and Antoine Zimmermann. Knowledge graphs. *ACM Computing Surveys*, 54(4) :1–37, 2021. doi : 10.1145/3447772. URL <https://doi.org/10.1145/3447772>.
- [3] Moin Nadeem, Anna Bethke, and Siva Reddy. Stereoset : Measuring stereotypical bias in pretrained language models. In *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1 : Long Papers)*, pages 5356–5371. Association for Computational Linguistics, 2021. doi : 10.18653/v1/2021.acl-long.416. URL <https://aclanthology.org/2021.acl-long.416/>. Dataset et code : <https://stereoset.mit.edu>.
- [4] M. Nadejde, S. Gabriel, and X. Li. Quelques observations sur la notion de biais dans les modèles de langue. In *Actes de la conférence JEPTALN-RECITAL 2023*, 2023. URL <https://aclanthology.org/2023.jeptalnrecital-statement.1.pdf>.
- [5] Nikita Nangia, Clara Vania, Rasika Bhalerao, and Samuel R. Bowman. Crows-pairs : A challenge dataset for measuring social biases in masked language models. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 1953–1967. Association for Computational Linguistics, 2020. doi : 10.18653/v1/2020.emnlp-main.154. URL <https://aclanthology.org/2020.emnlp-main.154/>. Dataset et code : <https://github.com/nyu-mll/crows-pairs>.
- [6] Alicia Parrish, Angelica Chen, Nikita Nangia, Vishakh Padmakumar, Jason Phang, Jana Thompson, Phu Mon Htut, and Samuel R. Bowman. BBQ : A hand-built bias benchmark for question answering. In *Findings of the Association for Computational Linguistics : ACL 2022*, pages 2086–2105. Association for Computational Linguistics, 2022. doi : 10.18653/v1/2022.findings-acl.165. URL <https://aclanthology.org/2022.findings-acl.165/>. Dataset et code : <https://github.com/nyu-mll/BBQ>.